GARBAGE CLASSIFICATION

Bruno Oliveira nº2019136478
Micael Eid nº2019112744

Indíce

- Descrição e objetivos do problema _____pg 3
- Descrição dos Algoritmos_____pg 4 e 5
- Análise de Resultados _____pg 6 a 16
- Conclusões_____pg 17

Descrição e objetivos do problema

- "O desenvolvimento que procura satisfazer as necessidades da geração atual, sem comprometer a capacidade das gerações futuras de satisfazerem as suas próprias necessidades, significa possibilitar que as pessoas, agora e no futuro, atinjam um nível satisfatório de desenvolvimento social, econômico e de realização humana e cultural, fazendo, ao mesmo tempo, um uso razoável dos recursos da terra e preservando as espécies e os habitats naturais." - Relatório Brundtland
- Este dataset (Garbage Classification) é composto por:
  - Imagens RGB.
  - Tamanho das imagens são aproximadamente 200x200.
  - Classes: 10 (metal, glass, biological, paper, battery, trash, cardboard, shoes, clothes, and plastic).
- Problema de classificação de 5 diferentes tipos de lixo para reciclagem (Papel, Vidro, Cartão, Plástico, Metal).

Descrição dos Algoritmos

Scripts Auxiliares:

- ResizeImg.m
- DeleteImg
- DeleteCMYK.m
- DividirDataSet.m

Divisão do Dataset:

- 70% para treino
- 15% para teste
- 15% para validação

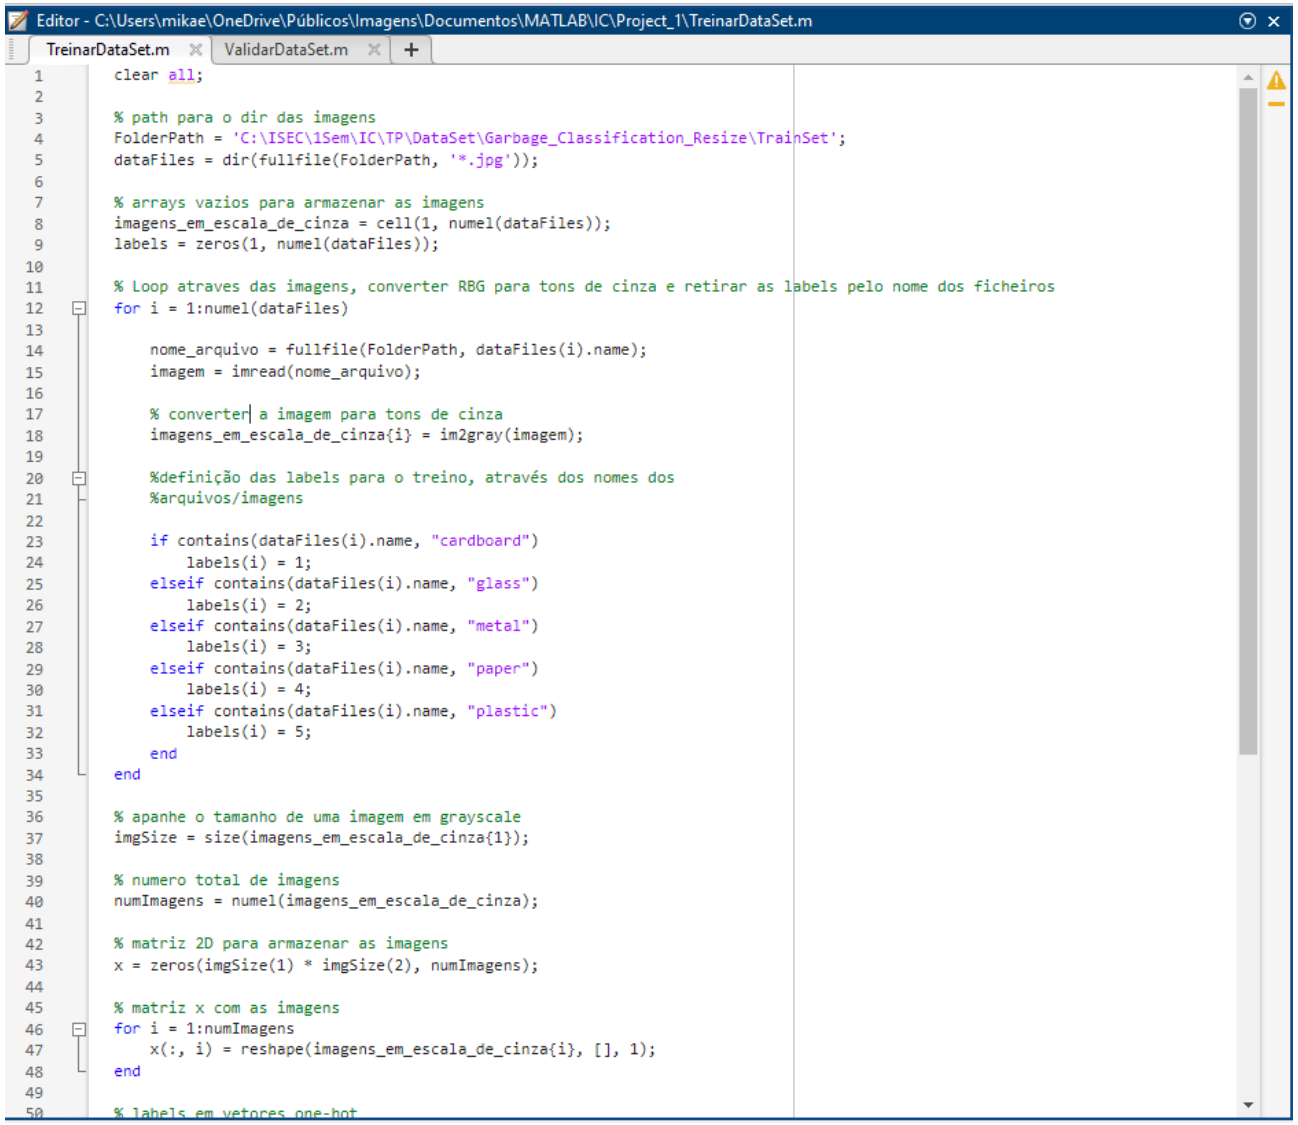

Treino, Validação e Teste

Devido à divisão das imagens do Dataset tivemos que atribuir os labels a cada uma das imagens, convertendoas imagens RGB para imagens com tom cinzento.

Análise de Resultados

- Realizámos vários tipos de testes com diferentes funções, camadas e número de neurónios, de maneira a obter resultados distintos, verificando o melhor.
- Estes testes tiveream recurso a Código dado nas aulas práticas.
- Todas as imagens foram enviadas em anexo no ficheiro .zip

Análise de Resultados

```
% rede neural e suas configurações para o treino

% camadas e neuronios e função de treino
net = patternnet(500);

% funções de ativação das camadas
net.layers{1}.transferFcn = 'tansig';
%net.layers{2}.transferFcn = 'tansig';
%net.layers{2}.transferFcn = 'tansig';

% função de ativação da camada output
%net.layers{end}.transferFcn = 'logsig';

% função de perda
net.performFcn = 'crossentropy';

% taxa de aprendizado
net.trainParam.lr = 1;

% numero max de epochs
net.trainParam.epochs = 1000;

% treino
net = train(net, x, t);
```

- 1 camada com 500 neurónios, ‘trainfcg’
  - Accuracy = 47.18%
  - Sensibilidade = 46.15%
  - Especificidade = 42.02%
  - F-measure = 0.46
  - AUC = 0.76

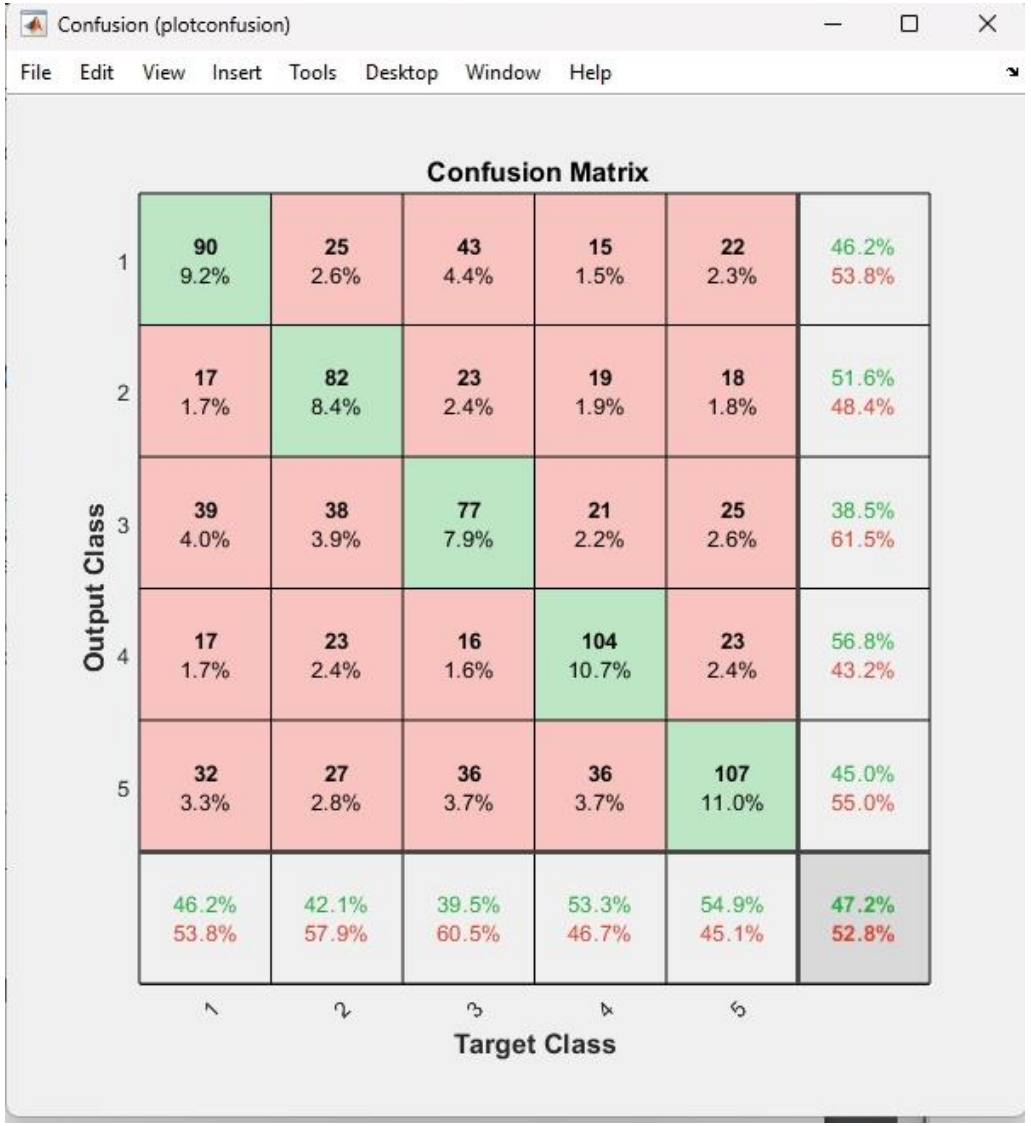

Análise de Resultados

Análise de Resultados

```
% rede neural e suas configurações para o treino

% camadas e neuronios e função de treino
net = patternnet([250 250]);

% funções de ativação das camadas
net.layers{1}.transferFcn = 'tansig';
net.layers{2}.transferFcn = 'tansig';
%net.layers{2}.transferFcn = 'tansig';

% função de ativação da camada output
%net.layers{end}.transferFcn = 'logsig';

% função de perda
net.performFcn = 'crossentropy';

% taxa de aprendizado
net.trainParam.lr = 1;

% numero max de epochs
net.trainParam.epochs = 1000;

% treino
net = train(net, x, t);
```

- 2 camadas com 250 neurónios, 'trainfcg'
  - Accuracy 48.51%
  - Sensibilidade = 48.21%
  - Especificidade = 49.23%
  - F-measure = 0.50
  - AUC = 0.78

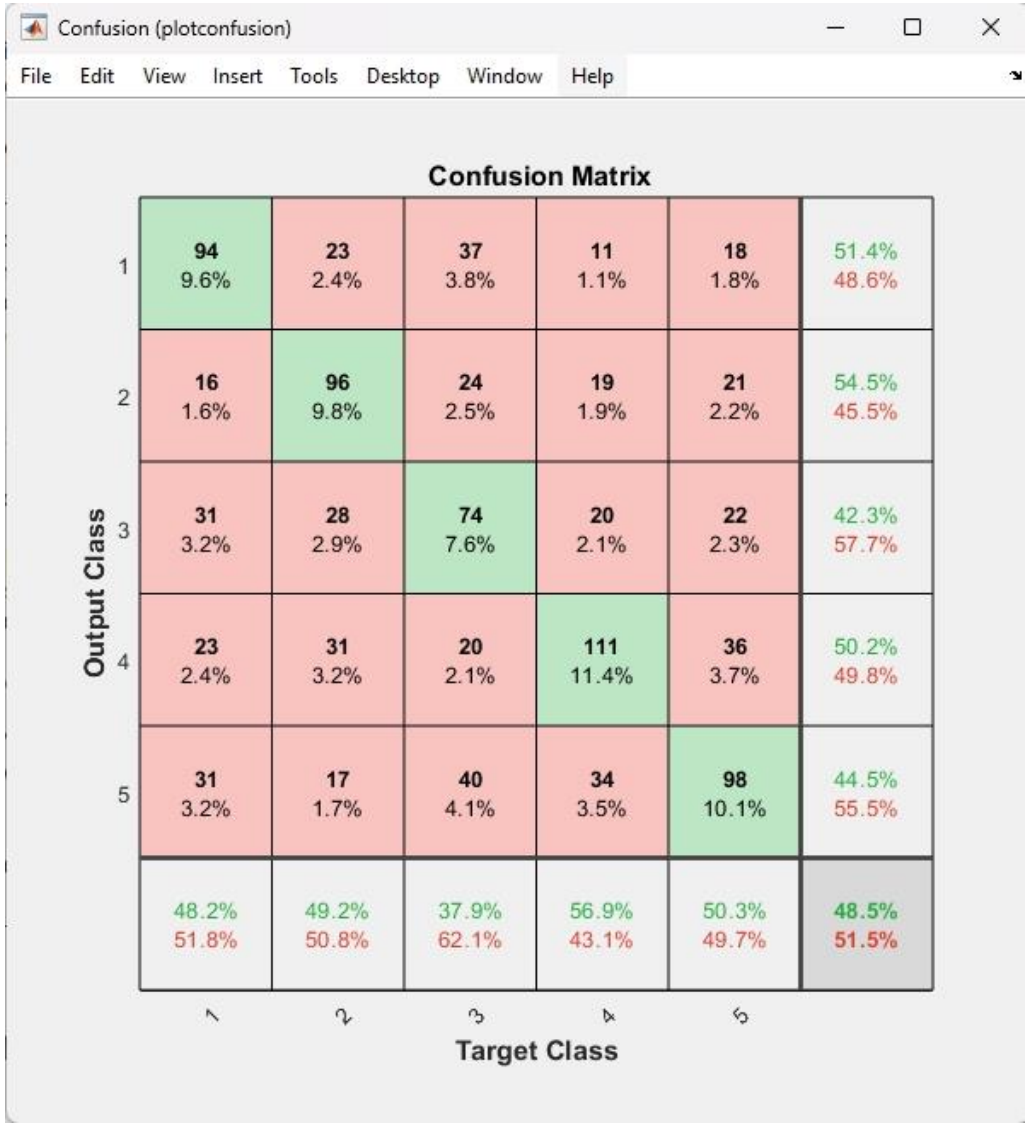

Análise de Resultados

Análise de Resultados

```
% camadas e neuronios e função de treino
net = patternnet([500 500 500]);

% funções de ativação das camadas
net.layers{1}.transferFcn = 'tansig';
net.layers{2}.transferFcn = 'tansig';
net.layers{3}.transferFcn = 'tansig';
%net.layers{4}.transferFcn = 'tansig';

% função de ativação da camada output
%net.layers{end}.transferFcn = 'logsig';

% função de perda
net.performFcn = 'crossentropy';

% taxa de aprendizado
net.trainParam.lr = 1;

% numero max de epochs
net.trainParam.epochs = 1000;

% treino
net = train(net, x, t);
```

- 3 camadas com 500 neurónios, ‘trainfcg’
  - Accuracy 49.03%
  - Sensibilidade = 45.64%
  - Especificidade = 51.79%
  - F-measure = 0.48
  - AUC = 0.77

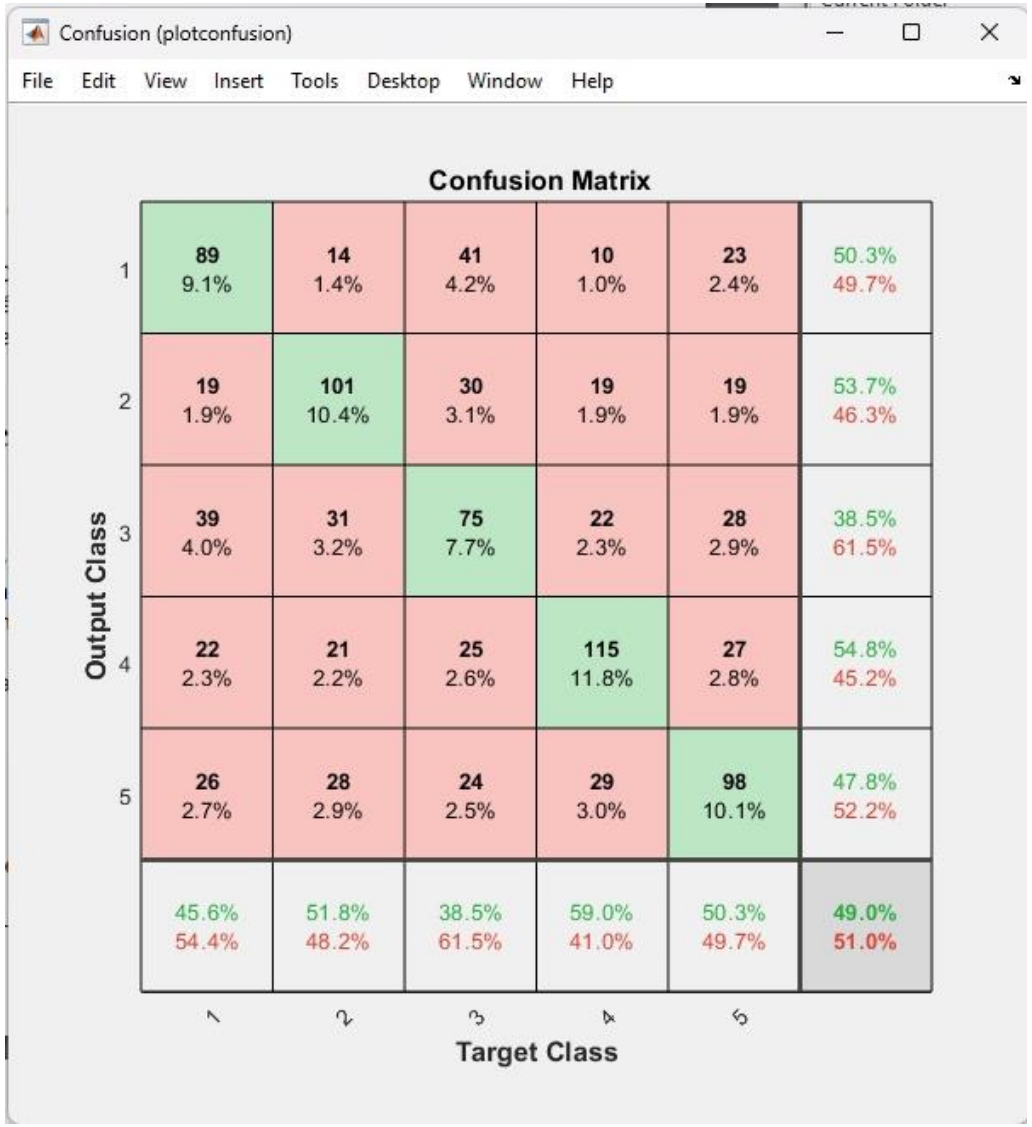

Análise de Resultados

Análise de Resultados

```
% rede neural e suas configurações para o treino

% camadas e neuronios e função de treino
net = patternnet([200 200 100 50], 'traincgp');

% funções de ativação das camadas
net.layers{1}.transferFcn = 'tansig';
net.layers{2}.transferFcn = 'tansig';
net.layers{3}.transferFcn = 'tansig';
net.layers{4}.transferFcn = 'tansig';

% função de ativação da camada output
%net.layers{end}.transferFcn = 'logsig';

% função de perda
net.performFcn = 'crossentropy';

% Valor de regularização
net.performParam.regularization = 0.1;

% taxa de aprendizado
net.trainParam.lr = 1;

% numero max de epochs
net.trainParam.epochs = 1000;

% treino
net = train(net, x, t);
```

- 4 camadas com 200 200 100 50 neurónios, 'traincgp' e adicioado o valor de regularização net.performParam.regularization = 0.1 (Overfitting)
  - Accuracy = 45.44%
  - Sensibilidade = 45.13%
  - Especificidade = 50.77%
  - F-measure = 0.45
  - AUC = 0.77

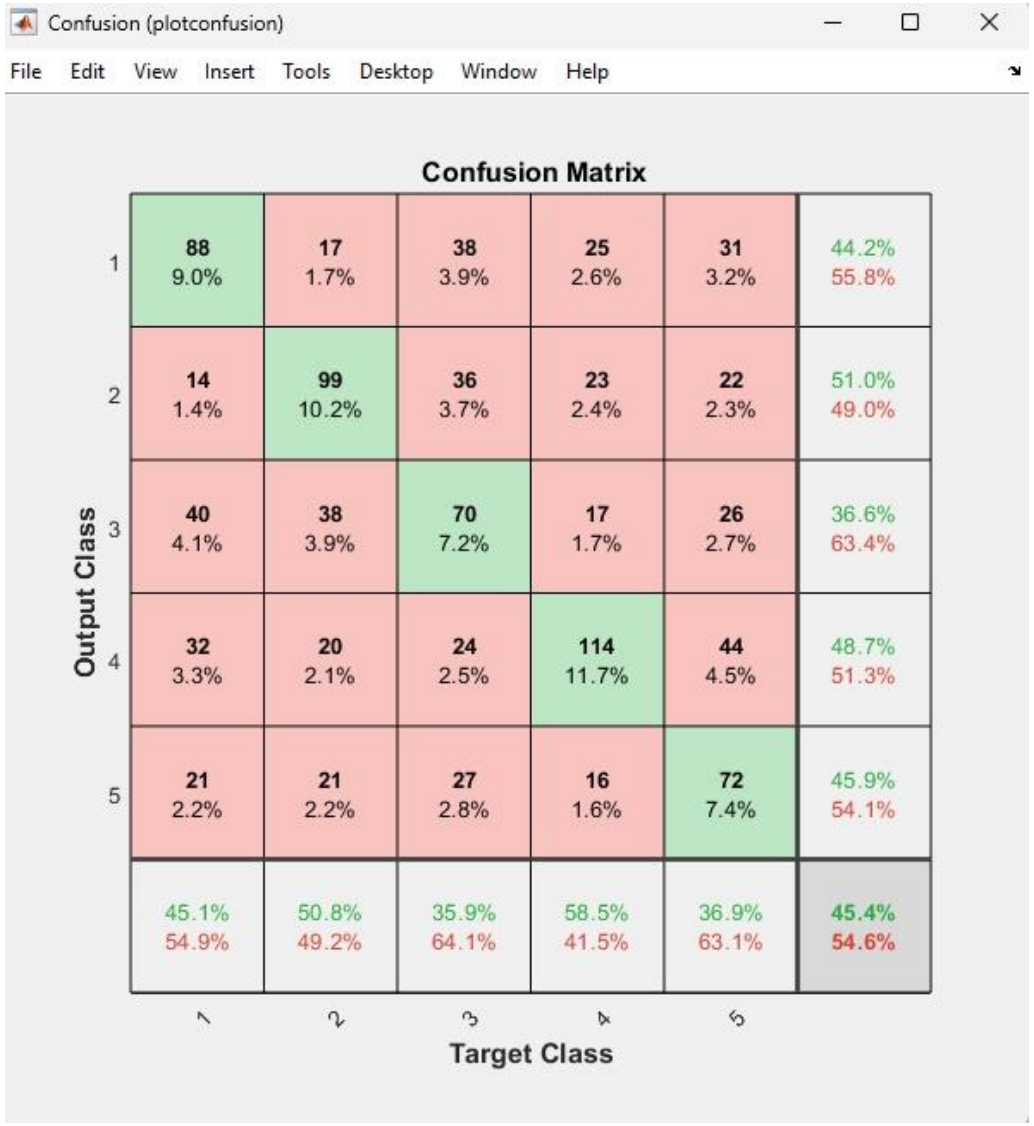

Análise de Resultados

Este foi o pior teste realizado com accuracy de 45.4%.

Análise de Resultados

```
% rede neural e suas configurações para o treino

% camadas e neuronios e função de treino
net = patternnet([500 500 250 100], 'traincgp');

% funções de ativação das camadas
net.layers{1}.transferFcn = 'tansig';
net.layers{2}.transferFcn = 'tansig';
net.layers{3}.transferFcn = 'tansig';
net.layers{4}.transferFcn = 'tansig';

% função de ativação da camada output
%net.layers{end}.transferFcn = 'logsig';

% função de perda
net.performFcn = 'crossentropy';

% Valor de regularização
net.performParam.regularization = 0.2;

% taxa de aprendizado
net.trainParam.lr = 1;

% numero max de epochs
net.trainParam.epochs = 1000;

% treino
net = train(net, x, t);
```

- 4 camadas com 500 500 250 100 neurónios, 'traincgp' e adicioado o valor de regularização net.performParam.regularization = 0.2 (Overfitting)
  - Accuracy = 52.82%
  - Sensibilidade = 46.67%
  - Especificidade = 52.31%
  - F-measure = 0.49
  - AUC = 0.79

Análise de Resultados

Este foi o melhor teste realizado com accuracy de 52.8%.

Conclusões

- Com a realização desta meta foi-nos possível adquirir novos conhecimentos sobre Matlab e a sua utilização para testes e treino, problemas de classsficação com recurso a dataset retirados online e criação de scripts para facilitar o processo de escrita e organização de Código.
- Tivemos algumas dificuldades com o tamanho do dataset e com a utilização das imagens RGB.
- Analisando os resultados obtidos, conseguimos verificar que estão baixos relativamente à Accuracy pretendida (acima de 90%).
- N meta 2 pretendemos melhorar o código com recurso à linguagem Python, aumentando os parâmetros pretendidos de Accuracy, Sensibilidade, Especificidade, F-Measure e AUC, tanto no teste como em treino.